

ERP/1: Істотність

Технічні вимоги

Локальна LLM-інфраструктура
для аналізу та оцінки істотності інформації

Зміст

Зміст

1	Умовні скорочення та визначення	3
2	Загальні відомості	4
2.1	Передумови	4
2.2	Питання, що вирішуються	4
2.3	Вимоги законодавства та міжнародних стандартів	4
3	Призначення та цілі впровадження	5
4	Класифікація вимог	6
4.1	Функціональні вимоги	6
4.1.1	Вимоги до локального RAG-контур та RocksDB/FAISS	6
4.1.2	Вимоги до автоматизованого знеособлення даних	6
4.1.3	Вимоги до оцінки якості та метрик RAG-Triad	6
4.2	Нефункціональні вимоги	6
4.2.1	Апаратні вимоги (NVIDIA GeForce RTX 4070 Ti)	6
4.2.2	Вимоги до програмного стеку	7
4.2.3	Вимоги до продуктивності та паралельного інференсу	7
4.2.4	Вимоги до безпеки та захисту інформації (NIST SP 800-53)	7
4.2.5	Вимоги до відмовостійкості (CPU Fallback / Peer-to-Peer)	7
5	Додаток А. Специфікація сутностей ШІ-вузла (для ТЗ)	8
6	Додаток Б. Технічні деталі RAG-контур та оркестрації K8s	8

Анотація

У цьому документі наведено детальні технічні вимоги до підсистеми ERP/1: Істотність, яка розробляється як сучасний інтелектуальний сервіс локального аналізу, семантичного пошуку та оцінки інформації на базі штучного інтелекту (ШІ). Платформа передбачає використання децентралізованих обчислювальних вузлів з споживчими GPU (NVIDIA GeForce RTX 4070 Ti) для локального виконання квантованих великих мовних моделей (LLM) та семантичного RAG-пошуку. Вимоги визначають архітектуру апаратного забезпечення, програмний стек, вимоги безпеки (КСЗІ, LUKS, TPM 2.0, Cilium), комплаєнс із стандартами NIST SP 800-53 та NIST AI 600-1, а також метрики оцінки якості та відмовостійкості системи в периферійному контурі.

1. Умовні скорочення та визначення

Терміни та скорочення, що використовуються в цьому документі:

Термін / Скорочення	Значення
LLM	Large Language Model (Белика мовна модель)
GPU	Graphics Processing Unit (Графічний процесор / відеокарта)
RAG	Retrieval-Augmented Generation (Генерація з доповненням пошуку)
VRAM	Video Random Access Memory (Відеопам'ять)
K8s	Kubernetes (Платформа оркестрації контейнерів)
TCO	Total Cost of Ownership (Сукупна вартість володіння)
NER	Named Entity Recognition (Розпізнавання іменованих сутностей)
TPM	Trusted Platform Module (Апаратний модуль безпеки)
KC3I	Комплексна система захисту інформації
ЄСІКС	Єдина судова інформаційно-комунікаційна система

2. Загальні відомості

2.1. Передумови

Сучасний етап цифровізації державних та корпоративних систем вимагає впровадження інтелектуальних інструментів для аналізу великих масивів документів, автоматизованого реферування та підготовки проектів рішень. Водночас, специфіка обробки конфіденційної інформації та персональних даних накладає суворі обмеження на архітектуру обчислювальних засобів:

1. **Конфіденційність (КСЗІ):** Відповідно до законодавства України, інформація з обмеженим доступом не може передаватися до сторонніх публічних хмарних сервісів (OpenAI, Anthropic, Google тощо). Обробка повинна відбуватися виключно в захищеному периметрі системи.
2. **Живучість:** Можливі блеаути, пошкодження каналів зв'язку та кібератаки вимагають повної автономності (Air-Gapped режим) ШІ-сервісів на місцях.
3. **Мінімізація затримок:** Локальний інференс безпосередньо в локальній мережі (LAN) усуває затримки передачі великих обсягів текстових документів.

Для вирішення цих завдань пропонується впровадити децентралізовані вузли обчислень у кожній установі на базі робочих станцій, інтегрованих у загальний контур ERP/1.

2.2. Питання, що вирішуються

Впровадження локальної ШІ-інфраструктури вирішує такі ключові завдання:

- Організація локального інференсу моделей надвисокої швидкості без ризику витоку інформації.
- Усунення галюцинацій мовної моделі через технологію локального семантичного RAG-пошуку.
- Автоматичне NER-знеособлення персональних даних перед передачею в мовну модель.
- Забезпечення централізованого управління великою кількістю периферійних вузлів.

2.3. Вимоги законодавства та міжнародних стандартів

Система повинна розроблятися та функціонувати відповідно до:

- Закону України «Про захист персональних даних»;
- Закону України «Про захист інформації в інформаційно-комунікаційних системах»;
- Стандарту безпеки NIST SP 800-53 Rev. 5 (контролі SC-28, SC-8, AC-3, AU-2);
- Рекомендацій профілю безпеки Generative AI Profile (NIST AI 600-1).

3. Призначення та цілі впровадження

Основною метою впровадження модуля є надання користувачам (наприклад, суддям, помічникам, аудиторам) інтелектуального асистента для аналізу документів, виявлення істотних зв'язків та автоматичної підготовки проектів рішень без загрози витоку конфіденційної інформації та з дотриманням вимог щодо безпеки on-premises обчислень.

4. Класифікація вимог

4.1. Функціональні вимоги

4.1.1. Вимоги до локального RAG-контурів та RocksDB/FAISS

Система повинна підтримувати локальний RAG (Retrieval-Augmented Generation) контур:

- Векторизація документів за допомогою моделі ембедінгів (multilingual-e5-large).
- Швидкий локальний пошук найближчих векторів у HNSW-індексах за допомогою бібліотеки FAISS.
- Зберігання метаданих та повних текстів рішень у швидкому локальному сховищі RocksDB.
- Асинхронна нічна синхронізація локальних баз із центральним об'єктним сховищем.

4.1.2. Вимоги до автоматизованого знеособлення даних

Перед відправкою тексту до ембедінг-моделі та збереженням у RocksDB/FAISS, матеріали справи проходять обов'язковий етап локального знеособлення:

- **NER-фільтрація:** виявлення в тексті ПІБ фізичних осіб, адрес проживання, номерів телефонів, державних номерів автомобілів тощо.
- **Маскування даних:** заміна конфіденційних сутностей на узагальнені токени ([ОСОБА_1], [АДРЕСА_1]).
- Локальне збереження таблиць відповідності в зашифрованій RocksDB під захистом TPM 2.0.

4.1.3. Вимоги до оцінки якості та метрик RAG-Triad

Для оцінки точності ШІ-сервісів система повинна вимірювати показники за трьома критеріями:

- **Context Relevance:** відповідність знайденого RAG-контексту запиту користувача.
- **Groundedness:** відсутність у генерованій відповіді тверджень, не підтверджених контекстом (боротьба з галюцинаціями).
- **Answer Relevance:** відповідність відповіді мовної моделі вихідному запиту користувача.

4.2. Нефункціональні вимоги

4.2.1. Апаратні вимоги (NVIDIA GeForce RTX 4070 Ti)

В якості периферійного апаратного прискорювача використовуються споживчі GPU NVIDIA GeForce RTX 4070 Ti (або RTX 4070 Ti Super). Технічні параметри наведено в таблиці:

Параметр	RTX 4070 Ti	RTX 4070 Ti Super
Об'єм VRAM	12 GB GDDR6X	16 GB GDDR6X
Шина пам'яті	192-bit	256-bit
Пропускна здатність	504 GB/s	672 GB/s
CUDA-ядра	7680	8448
Тензорні ядра	240 (4-gen)	264 (4-gen)
Енергоспоживання	285 W	285 W

4.2.2. Вимоги до програмного стеку

Локальний сервер функціонує під управлінням Linux-дистрибутива корпоративного класу (наприклад, Ubuntu LTS 24.04). Програмне забезпечення інференсу базується на:

- NVIDIA Proprietary Driver версії 550+ та CUDA Toolkit 12.x;
- Інференс-сервері llama.cpp або Ollama з низькорівневою оптимізацією під архітектуру Ada Lovelace;
- Бекенді на базі Erlang/Elixir для взаємодії через Port Drivers або локальний HTTP/gRPC API.

4.2.3. Вимоги до продуктивності та паралельного інференсу

Система повинна забезпечувати такі показники швидкості інференсу:

- Швидкість генерації для Llama-3-8B-Instruct (при Q4_K_M) — не менше 70 токенів/сек.
- Швидкість генерації для Llama-3-8B-Instruct (при Q8_0) — не менше 45 токенів/сек.
- Підтримка технології `continuous batching` для обслуговування одночасно від 5 до 8 активних користувачів на одну робочу станцію з RTX 4070 Ti без відчутного просідання швидкості.

4.2.4. Вимоги до безпеки та захисту інформації (NIST SP 800-53)

Захист інформації забезпечується на базі таких контролів:

- **SC-28 (Protection of Information at Rest)**: шифрування дискових накопичувачів NVMe за допомогою LUKS (AES-256) та зберігання ключів у апаратному TPM 2.0.
- **SC-8 (Transmission Confidentiality and Integrity)**: шифрування LAN-трафіку за допомогою HTTPS/gRPC з TLS 1.3.
- **AC-3 (Access Enforcement)**: інтеграція з доменною службою Active Directory/LDAP та розмежування прав на базі ABAC.
- **AU-2 (Event Logging)**: незмінне ведення журналів аудиту всіх запитів та відповідей ШІ-сервера.

4.2.5. Вимоги до відмовостійкості (CPU Fallback / Peer-to-Peer)

Для забезпечення безперервності процесів система повинна реалізовувати:

- **CPU Fallback**: автоматичний перехід інференсу на центральний процесор (AVX-512/AMX) у разі виходу з ладу GPU з падінням швидкості генерації до 8–12 токенів/сек.
- **Peer-to-Peer failover**: автоматичне перенаправлення запитів на сусідній периферійний вузол у межах регіону при повному збої локального сервера.

5. Додаток А. Специфікація сутностей ШІ-вузла (для ТЗ)

Для забезпечення роботи модуля «Істотність» у базі даних (Mnesia/KVS) ведуться такі реєстрові сутності:

1. **ai_node**: Дані про периферійний обчислювальний вузол (апаратні параметри, температура GPU, статус вузла).
2. **ai_model**: Параметри розгорнутих LLM та ембедінг моделей (шлях до файлу ваг, конфігурація квантування).
3. **ai_inference_task**: Журнал виконання запитів користувачів до ШІ (ідентифікатор користувача, промпт, час виконання).
4. **ai_anonymization_dictionary**: Зашифрована таблиця відповідностей для знеособлення персональних даних.

6. Додаток Б. Технічні деталі RAG-контурну та оркестрації K8s

Повна оркестрація 600+ периферійних вузлів здійснюється через централізований Kubernetes за методологією GitOps та інструментами автоматизації Ansible. Всі GGUF файли моделей та векторні індекси завантажуються в нічний час (cron Pull-механізм з 01:00 до 05:00) із центрального сховища Scality RING. Оновлення контейнерів інференсу проводиться за схемою Blue-Green Deployment для виключення простоїв сервісу.