

ERP/1: Істотність

Техноробочий проект

на створення та впровадження
локальної LLM-інфраструктури
для аналізу та оцінки істотності інформації

Згідно з Постановою КМУ № 205 від 21.02.2025

Формалізація вимог за стандартом ISO/IEC/IEEE 29148:2018

Зміст

Зміст

1	Загальні відомості про засіб інформатизації	2
1.1	Найменування та підстави для розробки	2
1.2	Призначення та цілі створення засобу	2
1.3	План-графік виконання етапів робіт	2
2	Відомості про робочий процес та умови експлуатації	3
2.1	Опис бізнес-процесів (BPMN / FSM)	3
2.1.1	Процес локального інференсу та RAG (ai_inference.erl)	3
2.1.2	Процес нічного оновлення моделей (ai_deployment.erl)	3
2.2	Опис ролей та прав доступу (ABAC)	3
2.3	Умови експлуатації та системне середовище	4
3	Інформаційне та програмне забезпечення	5
3.1	Інформаційне забезпечення (Схеми та Дані)	5
3.1.1	Визначення структур даних (Erlang Records)	5
3.2	Програмне забезпечення (Реалізація)	6
3.2.1	ai_inference.erl (DSL процесу RAG інференсу)	6
3.2.2	ai_validator.erl (Модуль валідації ШІ вузла)	7
4	Вимоги до засобу за ISO/IEC/IEEE 29148	8
4.1	Функціональні вимоги	8
4.2	Вимоги до інтерфейсів та дизайну	8
4.3	Вимоги до безпеки та захисту інформації	8
4.4	Вимоги до продуктивності та надійності	8
4.5	Вимоги до логування та аудиту	8
4.6	Адміністративні та юридичні вимоги	8

1. Загальні відомості про засіб інформатизації

1.1. Найменування та підстави для розробки

Найменування засобу інформатизації: Модуль «Істотність» (локальна ШІ-інфраструктура) у складі інформаційної системи управління підприємством ERP/1.

Підстави для виконання робіт:

- Закон України «Про захист персональних даних»;
- Закон України «Про захист інформації в інформаційно-комунікаційних системах»;
- Порядок використання засобів інформатизації (Постанова КМУ № 205 від 21.02.2025);
- Програма модернізації обчислювальної IT-інфраструктури ЄСІКС.

1.2. Призначення та цілі створення засобу

Модуль призначений для розгортання локальних інтелектуальних сервісів аналізу та семантичного пошуку з використанням великих мовних моделей (LLM) та векторних баз даних (RAG) безпосередньо on-premises на базі споживчих GPU NVIDIA RTX 4070 Ti.

Основні цілі створення:

- Забезпечення повного циклу локального інференсу LLM (Llama-3-8B-Instruct) із квантуванням ваг.
- Організація семантичного RAG-пошуку через RocksDB та FAISS.
- Автоматизація знеособлення вхідних документів (NER-маскування).
- Побудова оркестрованого контуру управління 600+ периферійними вузлами через K8s та Rancher за методологією GitOps.
- Реалізація відмовостійкості через CPU Fallback та Peer-to-Peer failover.

1.3. План-графік виконання етапів робіт

Розробка та впровадження модуля «Істотність» розділяється на такі етапи:

1. **Етап 1: Технічне проектування** — погодження UX/UI макетів, вибір цільових моделей ШІ, розробка схем даних. (1 місяць).
2. **Етап 2: Реалізація сховища даних та RAG** — налаштування RocksDB та індексів FAISS, розробка API-інтеграції з Erlang/OTP. (1.5 місяці).
3. **Етап 3: Розробка NER та знеособлення** — реалізація локального мікросервісу розпізнавання сутностей та маскування. (1 місяць).
4. **Етап 4: Налаштування оркестрації K8s та GitOps** — побудова кластера K8s, інтеграція GPU плагінів, оновлень. (1.5 місяці).
5. **Етап 5: Державна експертиза КСЗІ** — аудит безпеки, перевірка контролів NIST SP 800-53 та отримання атестату. (2 місяці).

2. Відомості про робочий процес та умови експлуатації

2.1. Опис бізнес-процесів (BPMN / FSM)

Всі процеси керування та роботи ШІ-сервісів формалізуються у вигляді кінцевих автоматів (FSM) та виконуються рушієм процесів BPE:

2.1.1. Процес локального інференсу та RAG (ai_inference.erl)

Цей процес відповідає за обробку запиту користувача до великої мовної моделі з додаванням RAG-контексту:

1. **StartInference:** Користувач надсилає текстовий запит (промпт) або документ.
2. **AnonymizePrompt:** Фоновий процес NER-фільтрації знеособлює чутливі дані, замінюючи їх на токени.
3. **GenerateEmbeddings:** Створення векторного представлення (ембедінгу) запиту через модель e5-large.
4. **VectorSearch:** Пошук відповідних фрагментів документів у FAISS за косинусною близькістю.
5. **BuildRAGPrompt:** Формування підсумкового промпту для LLM, де знеособлений запит поєднується зі знайденим контекстом.
6. **ExecuteInference:** Надсилання промпту до локального сервера llama.cpp на GPU RTX 4070 Ti.
7. **DeanonymizeResponse:** Зворотне відновлення персональних даних у згенерованій відповіді на базі локальної RocksDB таблиці відповідностей.
8. **InferenceCompleted:** Завершення процесу, повернення відповіді користувачу.

2.1.2. Процес нічного оновлення моделей (ai_deployment.erl)

Забезпечує автоматизоване GitOps-оновлення ваг моделей:

1. **TriggerUpdate:** Спрацювання cron-задачі о 01:00.
2. **CheckRemoteCatalog:** Перевірка наявності нових версій моделей у центральному сховищі Scality RING.
3. **VerifyDiskSpace:** Перевірка вільного місця на NVMe накопичувачі локального сервера.
4. **PullModelWeights:** Асинхронне скачування GGUF файлу ваг із обмеженням швидкості.
5. **VerifyChecksum:** Перевірка цілісності файлу за MD5/SHA256 хешами.
6. **RolloutBlueGreen:** Оновлення поду в K8s зі зміною монтування на новий файл моделі.
7. **VerificationTest:** Виконання тестового інференсу, перевірка GPU-метрик.
8. **DeploymentCompleted:** Фіксація успішного оновлення.

2.2. Опис ролей та прав доступу (ABAC)

Доступ до управління периферійними вузлами ШІ та перегляду журналів інференсу обмежується на базі ABAC:

```
allow(User, Action, Node) ->
  UserRole = maps:get(role, User),
  UserRegion = maps:get(region, User),
  NodeRegion = maps:get(region, Node),

  IsCDTO = (UserRole == cdto_admin),
  MatchesRegion = (UserRegion == NodeRegion),

  case {IsCDTO, Action} of
    {true, _} -> true;
    {false, view_metrics} -> MatchesRegion;
    {false, query_inference} -> true;
    _ -> false
  end.
```

2.3. Умови експлуатації та системне середовище

Робочі станції ШІ-серверів експлуатуються в приміщеннях канцелярій чи комутаційних шафах установ. Завдяки Midi-Tower корпусу та активному повітряному охолодженню RTX 4070 Ti, додаткове кондиціювання не є обов'язковим. Системне середовище включає Ubuntu LTS 24.04, драйвери NVIDIA 550+, CUDA 12.x та Docker/K8s runtime.

3. Інформаційне та програмне забезпечення

3.1. Інформаційне забезпечення (Схеми та Дані)

3.1.1. Визначення структур даних (Erlang Records)

Всі ключові сутності модуля описуються у вигляді рекорді Erlang:

```
-record(ai_node_status, {
    node_id,                % UUID вузла (PK)
    hostname,               % Текстове ім'я хоста
    ip_address,             % IP-адреса вузла
    gpu_temp = 0,           % Температура GPU RTX 4070 Ti в градусах
    vram_used = 0,          % Зайнято відеопам'яті (MB)
    vram_free = 0,          % Вільно відеопам'яті (MB)
    power_limit_pct = 80,   % Power Limit у відсотках (80% за замовчуванням)
    status = offline,       % online | offline | degraded | cooling_down
    last_seen_at = 0        % Timestamp останнього пінгу
}).

-record(ai_model_config, {
    model_id,               % UUID моделі (PK)
    name,                   % Назва моделі (напр. Llama-3-8B-Instruct)
    quant_type,             % Тип квантування (q4_k_m | q8_0)
    file_path,              % Шлях до GGUF файлу на NVMe
    checksum_sha256,        % Контрольна сума файлу
    context_window = 8192,  % Максимальний контекст (токенів)
    is_active = false,      % Чи завантажена модель у пам'ять GPU
    updated_at = 0
}).

-record(ai_anonymization_dictionary, {
    dict_id,                % UUID словника (PK)
    mapping_table = #{},    % Таблиця відповідностей {Token -> OriginalValue}
    created_at = 0,
    updated_at = 0
}).

-record(ai_inference_task, {
    task_id,                % UUID задачі (PK)
    user_id,                % UUID користувача, що надіслав запит
    node_id,                % UUID обчислювального вузла, який виконав запит
    prompt_hash,            % SHA256 хеш промпту
    response_hash,          % SHA256 хеш згенерованої відповіді
    tokens_generated = 0,   % Кількість згенерованих токенів
    time_taken_ms = 0,      % Час виконання запиту в мілісекундах
    status = pending,       % pending | processing | completed | failed
    created_at = 0
}).
```

```
-record(ai_rag_index_state, {
    index_id,                % UUID індексу (PK)
    num_vectors = 0,         % Кількість векторів
    file_path,               % Шлях до FAISS HNSW індексу
    last_sync_at = 0,        % Час останньої синхронізації з Scalify RING
    status = active          % active | syncing | stale
}).
```

3.2. Програмне забезпечення (Реалізація)

3.2.1. ai_inference.erl (DSL процесу RAG інференсу)

```
-module(ai_inference).
-include("bpe.hrl").
-compile(export_all).

def() ->
    #process{
        name = 'AI Inference and RAG Workflow',
        beginEvent = 'StartInference',
        endEvent = 'InferenceCompleted',
        tasks = [
            #beginEvent{name='StartInference'},
            #serviceTask{name='AnonymizePrompt', module=?MODULE},
            #serviceTask{name='GenerateEmbeddings', module=?MODULE},
            #serviceTask{name='VectorSearch', module=?MODULE},
            #serviceTask{name='BuildRAGPrompt', module=?MODULE},
            #serviceTask{name='ExecuteInference', module=?MODULE},
            #serviceTask{name='DeanonymizeResponse', module=?MODULE},
            #endEvent{name='InferenceCompleted'}
        ],
        flows = [
            #sequenceFlow{name='1', source='StartInference', target='AnonymizePrompt'},
            #sequenceFlow{name='2', source='AnonymizePrompt', target='GenerateEmbeddings'},
            #sequenceFlow{name='3', source='GenerateEmbeddings', target='VectorSearch'},
            #sequenceFlow{name='4', source='VectorSearch', target='BuildRAGPrompt'},
            #sequenceFlow{name='5', source='BuildRAGPrompt', target='ExecuteInference'},
            #sequenceFlow{name='6', source='ExecuteInference', target='DeanonymizeResponse'},
            #sequenceFlow{name='7', source='DeanonymizeResponse', target='InferenceCompleted'}
        ],
        roles = [operator, system]
    }.

action({serviceTask, 'AnonymizePrompt'}, Proc) ->
    % Виклик локального мікросервісу знеособлення NER
    {reply, Proc};
action({serviceTask, 'VectorSearch'}, Proc) ->
    % Пошук у локальному індексі FAISS
    {reply, Proc};
action({serviceTask, 'ExecuteInference'}, Proc) ->
    % Інференс на GPU RTX 4070 Ti через llama.cpp
    {reply, Proc};
action(_, Proc) -> {reply, Proc}.
```

3.2.2. ai_validator.erl (Модуль валідації ШІ вузла)

```
-module(ai_validator).  
-export([validate_model_hash/2, check_gpu_temperature/1]).  
  
validate_model_hash(FilePath, ExpectedHash) ->  
    case file:read_file(FilePath) of  
        {ok, Binary} ->  
            Calculated = crypto:hash(sha256, Binary),  
            case Calculated of  
                ExpectedHash -> ok;  
                _ -> {error, checksum_mismatch}  
            end;  
        _ -> {error, file_not_found}  
    end.  
  
check_gpu_temperature(GpuTemp) ->  
    MaxAllowed = 80,  
    if  
        GpuTemp > MaxAllowed -> {error, overheating};  
        true -> ok  
    end.
```


4. Вимоги до засобу за ISO/IEC/IEEE 29148

4.1. Функціональні вимоги

Модуль «Істотність» повинен виконувати аналіз завантажених документів, генерувати семантичні ембедінги, проводити знеособлення даних, здійснювати пошук контексту у RocksDB/FAISS та забезпечувати інференс мовної моделі.

4.2. Вимоги до інтерфейсів та дизайну

- Веб-інтерфейс адміністратора вузла повинен базуватися на фреймворку N2O/NITRO.
- Панель моніторингу повинна виводити статус GPU (температура, VRAM) та кількість активних сесій.
- Дизайн інтерфейсів має повністю відповідати стилю ERP/1 (Sleek Dark Mode).

4.3. Вимоги до безпеки та захисту інформації

- Шифрування розділів NVMe накопичувачів на базі LUKS з інтеграцією апаратного модуля TPM 2.0.
- Ізоляція мережевого трафіку ШІ від загального контуру LAN за допомогою Network Policies в CNI-плагіні Cilium.
- Заборона передачі будь-яких даних за межі локальної фізичної мережі установи (Air-Gapped режим).

4.4. Вимоги до продуктивності та надійності

- Середній показник доступності (SLA) периферійного сервера не менше 99.9%.
- Час відповіді на RAG-пошук (векторизація + FAISS) не більше 250 мс.
- Максимальний час перемикання на CPU при виході з ладу GPU не більше 15 секунд.

4.5. Вимоги до логування та аудиту

- Логування кожного запиту: ідентифікатор користувача, час, хеш промпту, хеш відповіді, згенеровані токени.
- Журнал аудиту повинен бути захищений від змін та автоматично передаватися на центральний сервер логування в нічний час.

4.6. Адміністративні та юридичні вимоги

- Всі компоненти ПЗ поставляються з відкритими ліцензіями (MIT/Apache 2.0).

- Застосування споживчих GPU RTX 4070 Ti у судах та офісних приміщеннях не підпадає під заборону використання GeForce у ЦОД (Datacenters) згідно з EULA NVIDIA, оскільки вузли є робочими станціями (Workstations) або крайовими пристроями (Edge Devices).